

Projeto de Sinais e Sistemas

Classificador de Doenças Cardíacas com ECG

Esdras Gabriel
Centro de Informática (CIn/UFPE)
Jaboatão, Brasil
egab@cin.ufpe.br

Gabriel Jatobá
Centro de Informática (CIn/UFPE)
Recife, Brasil
gjcms@cin.ufpe.br

Henrique César
Centro de Informática (CIn/UFPE)
Recife, Brasil
hchhc@cin.ufpe.br

João Victor
Centro de Informática (CIn/UFPE)
Olinda, Brasil
jvnl@cin.ufpe.br

Luiz Gustavo
Centro de Informática (CIn/UFPE)
Paudalho, Brasil
lgpss@cin.ufpe.br

Márcio André
Centro de Informática (CIn/UFPE)
Recife, Brasil
maacj@cin.ufpe.br

Abstract—Este trabalho apresenta um sistema automático para classificação de eletrocardiogramas (ECG) em três classes: infarto do miocárdio (MI), fibrilação atrial (AFIB) e ritmo sinusal normal (NORM). Utilizando o dataset PTB-XL e um classificador Random Forest, o modelo obteve acurácia geral de 79,25% e concordância moderada (Cohen's Kappa = 0,471). O desempenho variou entre classes, com recall de 92,0% para NORM, 47,6% para MI e 46,3% para AFIB. Os resultados indicam viabilidade técnica real, mas reforçam a necessidade de aprimorar a abordagem para classificação específica das classes.

Index Terms—ECG, Eletrocardiograma, Random Forest, Machine Learning, Sinais, Saúde.

I. INTRODUÇÃO

As doenças cardiovasculares permanecem entre as principais causas de mortalidade no mundo, sendo a detecção e prevenção precoces fatores determinantes para reduzir seus impactos clínicos e sociais. O eletrocardiograma (ECG) é um exame amplamente utilizado para esse fim, por ser rápido, seguro, não invasivo e de baixo custo. Ele registra a atividade elétrica do coração por meio de múltiplas derivações, permitindo identificar anomalias como arritmias, bloqueios, infarto do miocárdio e fibrilação atrial.

A interpretação manual de ECGs exige conhecimento especializado e está sujeita a variabilidade inter e intra-observador. Nesse contexto, ferramentas computacionais baseadas em processamento digital de sinais e aprendizado de máquina têm ganhado destaque, oferecendo diagnósticos de triagem mais rápidos e consistentes. Modelos automáticos podem ser empregados como sistemas de apoio à decisão clínica, auxiliando médicos a detectar alterações críticas mesmo em ambientes com recursos limitados.

O dataset PTB-XL, lançado em 2020, consolidou-se como uma das bases públicas mais relevantes para pesquisa nessa área, contendo mais de 21 mil registros clínicos de ECG de 12 derivações, anotados por especialistas e padronizados segundo o protocolo SCP-ECG. Esse conjunto de dados fornece suporte robusto para o desenvolvimento e validação de algoritmos de classificação de sinais cardíacos.

Neste trabalho, é proposto um sistema automático de classificação de ECG voltado para três condições: infarto do miocárdio (MI), fibrilação atrial (AFIB) e ritmo sinusal normal (NORM). O método combina pré-processamento com filtragem e normalização, extração de características nos domínios temporal, frequencial e informacional (entropia de Shannon) e classificação utilizando o algoritmo Random Forest. A escolha desse classificador foi motivada por sua robustez a overfitting, capacidade de lidar com múltiplos atributos correlacionados e facilidade de interpretação. Os resultados obtidos indicam o potencial do sistema para aplicações em triagem automatizada, embora melhorias sejam necessárias para sensibilidade adequada em condições críticas.

II. OBJETIVO

Geral

- Desenvolver um classificador de eletrocardiogramas (ECG) capaz de identificar infarto do miocárdio (MI), fibrilação atrial (AFIB) e ritmo sinusal normal (NORM), utilizando técnicas de processamento digital de sinais e aprendizado de máquina.

Específicos

- Extrair características relevantes nos domínios temporal, frequencial e informacional (entropia de Shannon) para representar os sinais de forma discriminativa;
- Treinar, otimizar e validar o modelo utilizando o algoritmo *Random Forest* e métodos de ajuste de hiperparâmetros como *Grid Search*;
- Avaliar o desempenho do sistema com métricas estatísticas e clínicas, considerando sensibilidade, especificidade, precisão, F1-score e concordância de Cohen (Kappa);
- Analisar a viabilidade do uso do sistema como ferramenta de apoio à decisão médica, identificando limitações e possíveis melhorias para aplicação prática.

III. METODOLOGIA

O desenvolvimento do sistema foi estruturado em um pipeline composto por quatro etapas principais: pré-processamento, extração de características, treinamento do modelo e avaliação do modelo. Todo o processo foi implementado em Python, utilizando bibliotecas especializadas para processamento de sinais e aprendizado de máquina.

A. Banco de dados

Foi utilizado o bando de dados público *PTB-XL*, que contém 21.837 registros de ECG de 12 derivações, com duração de 10 segundos cada. Os registros seguem o padrão *SCP-ECG* e foram anotados por especialistas, incluindo diagnósticos clínicos, características morfológicas e dados demográficos. Para este trabalho, foram selecionadas três classes de interesse:

- **MI (Infarto do Miocárdio):** 4841;
- **AFIB (Fibrilação Atrial):** 1002;
- **NORM (Normal/Saudável):** 14583;

B. Pré-processamento dos Dados

O sinal bruto passou por um pipeline de limpeza e padronização:

- **Filtragem Digital:** Aplicação de diferentes tipos de filtros para remover ruído e componentes indesejados do sinal se necessário;
- **Normalização e Condicionamento do Sinal:** Aplicação da técnica de normalização *Z-score* para padronizar os sinais;

C. Extração de Características

Após uma breve pesquisa, optou-se pelo uso dos extratores que apresentaram-se relevantes para as classificações das classes escolhidas, porém decidiu-se extrair as características mais gerais dos domínios temporais, frequenciais e informacionais, acreditando-se que poderia fornecer uma melhor descrição, dessa forma resultando em um total de 252 características por canal, distribuídas nos seguintes grupos:

- **Domínio do Tempo:** média, desvio padrão, curtose, assimetria, valores extremos, energia, potência e cruzamentos por zero;
- **Domínio da Frequência:** obtido via Transformada de Fourier, incluindo frequência dominante, magnitude associada, centroide espectral, largura de banda e energia em faixas específicas;
- **Domínio de Informação:** Entropia de Shannon para mensuração da complexidade do sinal, associada a irregularidades típicas de condições cardíacas.

D. Seleção do Modelo

Durante o debate e pesquisa, a equipe propôs a utilizar um modelo de *Machine Learning* mais clássico e de mais fácil implementação, além verificadamente possível para a proposta de classificar um ECG, como mostrado nas pesquisas usadas como base. Portanto foi escolhido um modelo Random Forest, por sua robustez a overfitting, capacidade de lidar com atributos correlacionados e facilidade de interpretação por meio da importância das variáveis.

E. Treinamento do Modelo

Após a preparação das funções básicas do modelo, e outras funções auxiliares, foi realizado um carregamento dos dados processados, com todas as características, das classes a serem classificadas e então separado o banco de dados entre conjunto de treino e teste, 80% e 20% respectivamente, com a distribuição individual das classes na mesma proporção. Para o ajuste dos hiperparâmetros, foi realizado um *Grid Search* com uma amostra de 324 registros além do uso de um esquema de validação cruzada com 5 folds para definir a estabilidade e robustez do modelo. Após os ajustes, realizou-se o treinamento completo do modelo, que durou um total de 4 horas 21 minutos e 22 segundos até a conclusão de todo o banco de dados.

F. Avaliação do Modelo

A avaliação foi realizada em conjunto de teste separado (20% dos dados), com métricas estatísticas e clínicas: precisão, recall, F1-score e o Cohen's Kappa. Também foi analisada a matriz de confusão para identificar padrões de erros entre classes.

IV. RESULTADOS

Nesta seção, seguem alguns os resultados, que a equipe considerou importante, obtidos a partir da análise exploratória dos dados e da avaliação dos modelos preditivos:




Fig. 1. Comparação do Sinal processado em 2 de suas 12 derivações




Fig. 2. Descrição das características do domínio do tempo em 1000 amostras




Fig. 3. Descrição das características do domínio do tempo em 1000 amostras




Fig. 4. Descrição da Entropia de Shannon para todas as derivações de 1 sinal completo




Fig. 5. Resultado dos testes




Fig. 6. Métricas dos resultados dos testes

V. DISCUSSÃO E LIMITAÇÕES

Os resultados mostram acurácia global aceitável (79,25%) porém sensibilidade reduzida para MI e AFIB (recall $\approx$ 47–46%), enquanto NORM apresenta alta sensibilidade (92%). A matriz de confusão (Figura 5) indica que muitos casos de MI foram classificados como NORM, o que teria implicações clínicas graves. Fatores prováveis:

- Características muito gerais;
- Features mal escolhidas para distinguir alterações isquêmicas/arrítmicas semelhantes;
- Organização das classes, exemplo de IM que possui 5 subclasses com morfologia diferentes.
- Pré-processamento e seleção de features ainda podem ser otimizados (feature selection, engenharia específica por classe).

Ressalta-se que o pré-processamento e seleção de features ainda podem ser otimizados (feature selection, engenharia específica por classe).

VI. CONCLUSÃO

Este trabalho apresentou um pipeline para classificação de ECG em três classes (MI, AFIB e NORM), integrando pré-processamento reprodutível, extração de 252 características por canal (domínios temporal, frequencial e informacional) e modelagem via Random Forest. Nos testes com PTB-XL, o sistema alcançou acurácia de 79,25%, F1-weighted de 0,780 e concordância moderada (Cohen's Kappa = 0,471), com estabilidade entre validação cruzada e teste final (diferença $\leq$ 0,01), evidenciando baixo overfitting. Em termos clínicos, o desempenho foi heterogêneo: recall elevado para NORM (0,920) e sensibilidade insuficiente para MI (0,476) e AFIB (0,463). A matriz de confusão revelou que cerca de metade dos MI foi classificada como NORM, o que inviabiliza uso real do modelo.

Porém, em um escopo mais amplos, os resultados confirmam a viabilidade técnica para implementação mais simples, triagem automatizada e apoio à decisão, com ganhos claros de qualidade após o pré-processamento (filtragem, normalização e verificação automática de SNR/saturação). Seguindo a discussão das limitações desse modelo implementado, ainda há

bastante espaço para melhoria, principalmente se corrigirmos o uso indevido das características para essa classificação. Em suma, o sistema é promissor, mas requer aumento de sensibilidade para MI/AFIB e validação clínica adicional antes de implantação em cenários reais.

VII. REFERÊNCIAS

- [1] S. Aziz, S. Ahmed, and M. S. Alouini, “ECG-based machine-learning algorithms for heartbeat classification,” *Scientific Reports*, vol. 11, no. 1, pp. 1–12, 2021. [Online]. Available: <https://www.nature.com/articles/s41598-021-97118-5>.
- [2] S. Śmigiel, K. Pałczyński, and D. Ledziński, “ECG signal classification using deep learning techniques based on the PTB-XL dataset,” *Entropy*, vol. 23, no. 9, p. 1121, 2021. [Online]. Available: <https://www.mdpi.com/1099-4300/23/9/1121>.
- [3] P. Wagner, N. Strodthoff, R.-D. Boussejot, et al., “PTB-XL, a large publicly available electrocardiography dataset,” *Scientific Data*, vol. 7, no. 1, p. 154, 2020. [Online]. Available: <https://www.nature.com/articles/s41597-020-0495-6>.
- [4] P. Martinez, et al., “Detection of Arrhythmic Cardiac Signals from ECG Recordings Using the Entropy–Complexity Plane,” *Proceedings*, vol. 46, no. 1, p. 8, 2019. [Online]. Available: <https://www.mdpi.com/2504-3900/46/1/8>.
- [5] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. [Online]. Available: <https://link.springer.com/article/10.1023/A:1010933404324>.
- [6] F. Pedregosa, G. Varoquaux, A. Gramfort, et al., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>.