

Sinais e Sistemas (ES413) – Cin/UFPE

Projeto: Detecção de Anomalias Cardiológicas em ECC

Ashtaiwi et al. (2024) chamam a atenção para a possibilidade de reduzir os efeitos maléficos de doenças cardíacas através de detecção e prevenção precoces. Para isso, o eletrocardiograma (ECG) é amplamente empregado. O uso de ferramentas computacionais melhora a capacidade de análise e diagnóstico de ECGs, ajudando nos cuidados com pacientes.

Um ECG consiste em uma representação gráfica dos potenciais elétricos gerados pelo coração (Anand et al., 2022). Esse é um exame rápido, seguro, não invasivo, barato e indolor, muito empregado no diagnóstico de arritmias, anormalidades de condução, hipertrofia ventricular e infarto do miocárdio. Cada onda de ECG é rotulada em ordem alfabética: P, Q, R, S, T, U (Figura 1). A onda P representa a despolarização atrial; o complexo QRS representa a despolarização ventricular; enquanto o complexo ST-T-U representa a repolarização ventricular. Em geral, emprega-se 10 eletrodos para gerar 12 derivações de ECG convencionais, usualmente agrupadas em seis derivações de membros (I, II, III, aVL, aVR e aVF) que detectam alterações no potencial elétrico no plano frontal e seis derivações torácicas (V1, V2, V3, V4, V5 e V6) que determinam o potencial no plano horizontal.




Figura 1: Morfologia de um ECG normal.

A análise da imagem do ECG permite diagnosticar diferentes condições cardíacas, como ritmos cardíacos irregulares, doença arterial coronariana (DAC), insuficiência cardíaca, infarto do miocárdio (IM), batimento cardíaco anormal (Abn-HB), histórico de infarto do miocárdio (His-IM) e doenças cardíacas estruturais, além de permitir identificar um coração saudável (Li & Boulanger, 2020).

Tipicamente, os modelos de Aprendizagem de Máquinas utilizam extratores de características que alimentam modelos classificatórios para os sinais de ECG. Portanto, os desempenhos de tais modelos dependem da qualidade das características extraídas. Há um conjunto de modelos que utiliza Transformada de Fourier (Serhal et al., 2022; Singhal et al., 2020; Lin, 2008) para extrair características ou para separar sinais de perturbações. Os classificadores atuais utilizam modelos supervisionados de redes neurais, rasas ou profundas (Aziz et al., 2021).

Cardiologistas podem fazer bom uso de algoritmos de interpretação automática de ECG como sistemas de apoio ao diagnóstico. Para desenvolver esses algoritmos, são necessários grandes conjuntos de dados de treinamento além de procedimentos de referência claros. Strodthoff et al. (2020) e Wagner et al. (2023) introduziram uma base de dados chamada ECG PTB-XL, formada por 21.799 ECGs clínicos de 12 derivações, de 18.869 pacientes, com

duração de 10 segundos. Os dados brutos da forma de onda foram anotados por até dois cardiologistas que produziram potencialmente múltiplas declarações de ECG a cada registro. No total, 71 declarações de ECG diferentes estão em conformidade com o padrão SCP-ECG e abrangem declarações de diagnóstico, forma e ritmo. O conjunto de dados inclui ainda dados demográficos, características do infarto, probabilidades para declarações de ECG diagnóstico, além de propriedades de sinais anotadas.

Objetivo:

Construir um modelo para diagnóstico de anomalias cardíacas (e também coração normal) baseadas em eletrocardiograma (ECG), atendendo as especificações a seguir.

Especificações:

1. Os dados de ECG podem ser encontrados em bases de domínio público como a PTB-XL ECG *dataset*.
2. Cada grupo deve selecionar os métodos de pré-processamento (se necessário) um algoritmo de reconhecimento de padrões para atuar juntamente com a Transformada de Fourier (componente obrigatório) e ao menos um outro extrator de características.
3. Cada grupo deve procurar diferentes tecnologias para o reconhecimento de anomalias cardíacas.
4. Dois ou três outros tipos de extração de características devem ser escolhidos por cada grupo para melhorar desempenho do reconhecedor, sendo que um deles obrigatoriamente deve usar Transformada de Fourier.

Equipes:

1. Cada equipe terá até 5 estudantes sendo um deles o líder.
 - a. Será permitida uma equipe com 3 ou 4 alunos ou até 2 equipes com 6 alunos no caso do número total de alunos que fará o trabalho não ser múltiplo de 5.
2. Cada aluno selecionará sua equipe e isto será feito em sala de aula.
3. O(s) monitor(es) ajudará(ão) as equipes no seu projeto.

Avaliação:

1. O projeto valerá 50% da segunda nota, os outros 50% será da segunda prova.
2. Os projetos estarão competindo entre si. Eles serão avaliados nos quesitos de formalização, criatividade e funcionalidades.
3. A participação de cada aluno é opcional. Porém, se o aluno decidir participar do projeto ele receberá a nota por sua participação. Em caso de desistência receberá nota 0 (zero).
4. Os alunos terão suas notas de forma decrescente, sendo a(s) equipe(s) ganhadora(s) com pontuação máxima. É possível que haja empates de notas.

5. Cada equipe será acompanhada de perto pelo(s) monitores(s) e componentes que não estejam cooperando serão dispensados da equipe e receberão nota zero.
6. Adição de funcionalidades coerentes com o escopo do projeto trará melhor pontuação à equipe.
7. Atrasos nas entregas do projeto gera perda da nota (10% ao dia).
8. Não pode haver dois grupos com a mesma combinação de componentes nos modelos.
9. A entrega do relatório do projeto se dará em 15/08/2025, quando ocorrerá a apresentação dos projetos.
10. Cada aluno será avaliado individualmente por sua apresentação oral e em grupo pelo conteúdo do projeto escrito.
11. O tempo de cada aluno na apresentação deve ser o mais equânime possível. Variações no tempo (para cima ou para baixo) acarretarão prejuízo da nota.
12. Haverá entregas intermediárias obrigatórias de cada projeto.

Datas importantes:

09/07/2025: Data limite para definição dos grupos. Cada grupo deve ser postado no mural da disciplina e seu líder indicado.

11/07/2025: Data limite para postagem nas atividades do *classroom* da escolha do algoritmo classificador (deve ter uma justificativa baseada em trabalhos anteriores). O documento deve ter até 2 (duas) páginas.

16/07/2025: Data limite para postagem nas atividades do *classroom* da escolha dos extratores de características, mínimo de 2 e máximo de 3 opções. Deve ter uma justificativa baseada em trabalhos anteriores. Além disso, deve ser especificados os dois problemas cardiológicos a serem tratados pelo modelo. É preciso informar o que irá usar para pré-processamento também. Vale 1 (um) ponto.

15/08/2025: Apresentação do projeto.

Contato da monitora:

Matheus Augusto Monte Silva <mams4@cin.ufpe.br>

Referências:

- Anand, A., Kadian, T., Shetty, M. K., & Gupta, A. (2022). Explainable AI decision model for ECG data of cardiac disorders. *Biomedical Signal Processing and Control*, 75, 103584.
- Ashtaiwi, A., Khalifa, T., & Alir, O. (2024). Enhancing heart disease diagnosis through ECG image vectorization-based classification. *Heliyon*, 10(18).
- Aziz, S., Ahmed, S., & Alouini, M. S. (2021). ECG-based machine-learning algorithms for heartbeat classification. *Scientific reports*, 11(1), 18738.
- Li, H., & Boulanger, P. (2020). A survey of heart anomaly detection using ambulatory electrocardiogram (ECG). *Sensors*, 20(5): 1461.
- Lin, C. H. (2008). Frequency-domain features for ECG beat discrimination using grey relational analysis-based classifier. *Computers & Mathematics with Applications*, 55(4), 680-690.

Strodthoff, N., Mehari, T., Nagel, C., Aston, P. J., Sundar, A., Graff, C., Kanters, J., Haverkamp, W., Doessel, O., Loewe, A., Bar, M., & Schaeffter, T. (2023). PTB-XL+, a comprehensive electrocardiographic feature dataset. *Scientific Data*, 10(1), 279.

Śmigiel, S., Pałczyński, K., & Ledziński, D. (2021). ECG signal classification using deep learning techniques based on the PTB-XL dataset. *Entropy*, 23(9), 1121.

Wagner, P., Strodthoff, N., Bousseljot, R. D., Kreiseler, D., Lunze, F. I., Samek, W., & Schaeffter, T. (2020). PTB-XL, a large publicly available electrocardiography dataset. *Scientific Data*, 7(1): 1-15.

Serhal, H., Abdallah, N., Marion, J. M., Chauvet, P., Oueidat, M., & Humeau-Heurtier, A. (2022). Overview on prediction, detection, and classification of atrial fibrillation using wavelets and AI on ECG. *Computers in Biology and Medicine*, 142, 105168.

Singhal, A., Singh, P., Fatimah, B., & Pachori, R. B. (2020). An efficient removal of power-line interference and baseline wander from ECG signals by employing Fourier decomposition technique. *Biomedical Signal Processing and Control*, 57, 101741.

Links interessantes:

<https://paperswithcode.com/dataset/ptb-xl>
<https://physionet.org/content/ptb-xl/1.0.3/>
<https://physionet.org/content/ptb-xl-plus/1.0.1/>

Vídeos interessantes:

<https://www.youtube.com/watch?v=YQcR02EEWKg>
https://www.youtube.com/watch?v=FG7__Baq9Ok
<https://www.youtube.com/watch?v=YoxqQibrOZ8>
<https://www.youtube.com/watch?v=GMtxB8RrNWM>
<https://www.youtube.com/shorts/VjfJYnFudsQ>